



# Analyse des Avis Clients des Agences Bancaires au Maroc

Conception et Implémentation d'un Entrepôt de Données Moderne

## Projet de Data Warehouse et Business Intelligence

Master Systèmes d'Information et Systèmes Intelligents

Réalisé par :

Mohammed DECHRAOUI

Étudiant en 1<sup>re</sup> année du Master M2SI

Encadré par :

Dr. BENELALLAM Imade

Professeur à l'INSEA

Institut National de Statistique et d'Économie Appliquée

Rabat, Royaume du Maroc

Année Académique : 2024-2025

10 juin 2025

# Table des matières

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Résumé Exécutif</b>                                            | <b>4</b>  |
| 1.1      | Objectifs Stratégiques . . . . .                                  | 4         |
| 1.2      | Approche Méthodologique . . . . .                                 | 4         |
| 1.3      | Résultats Attendus . . . . .                                      | 4         |
| <b>2</b> | <b>Introduction et Contexte du Projet</b>                         | <b>4</b>  |
| 2.1      | Paysage Bancaire Marocain . . . . .                               | 4         |
| 2.1.1    | Caractéristiques du Marché . . . . .                              | 5         |
| 2.1.2    | Défis Sectoriels Contemporains . . . . .                          | 5         |
| 2.2      | Problématique de Recherche . . . . .                              | 5         |
| 2.2.1    | Lacunes Identifiées dans l'Écosystème Actuel . . . . .            | 5         |
| 2.3      | Opportunités Technologiques . . . . .                             | 6         |
| 2.3.1    | Émergence du Modern Data Stack . . . . .                          | 6         |
| 2.3.2    | Avantages du Modern Data Stack . . . . .                          | 6         |
| 2.4      | Objectifs du Projet . . . . .                                     | 6         |
| 2.4.1    | Objectif Principal . . . . .                                      | 6         |
| 2.4.2    | Objectifs Spécifiques . . . . .                                   | 6         |
| 2.5      | Contributions Techniques . . . . .                                | 7         |
| 2.6      | Justification Académique et Professionnelle . . . . .             | 7         |
| 2.6.1    | Alignement avec la Formation M2SI . . . . .                       | 7         |
| 2.6.2    | Pertinence Professionnelle . . . . .                              | 7         |
| 2.6.3    | Impact Sociétal . . . . .                                         | 7         |
| <b>3</b> | <b>Revue de Littérature et État de l'Art</b>                      | <b>8</b>  |
| 3.1      | Fondements Théoriques . . . . .                                   | 8         |
| 3.1.1    | Théorie des Entrepôts de Données . . . . .                        | 8         |
| 3.1.2    | Analyse de Sentiment . . . . .                                    | 8         |
| 3.2      | Technologies du Modern Data Stack . . . . .                       | 8         |
| 3.2.1    | Évolution Architecturale . . . . .                                | 8         |
| 3.2.2    | Composants Clés . . . . .                                         | 9         |
| 3.3      | Analyse de Sentiment dans le Secteur Bancaire . . . . .           | 9         |
| 3.3.1    | Spécificités Sectorielles . . . . .                               | 9         |
| 3.3.2    | Défis Linguistiques au Maroc . . . . .                            | 9         |
| <b>4</b> | <b>Architecture Technique Détaillée</b>                           | <b>10</b> |
| 4.1      | Structure Fonctionnelle du Pipeline d'Analyse . . . . .           | 10        |
| 4.2      | Choix Technologiques Justifiés . . . . .                          | 11        |
| 4.2.1    | Couche de Collecte . . . . .                                      | 11        |
| 4.2.2    | Couche de Stockage . . . . .                                      | 11        |
| 4.2.3    | Couche de Transformation . . . . .                                | 12        |
| 4.3      | Patterns Architecturaux Appliqués . . . . .                       | 12        |
| 4.3.1    | Extract, Load, Transform (ELT) . . . . .                          | 12        |
| 4.3.2    | Organisation des Données selon l'Architecture Médaillon . . . . . | 12        |

|          |                                                        |           |
|----------|--------------------------------------------------------|-----------|
| <b>5</b> | <b>Collecte et Ingestion des Données</b>               | <b>13</b> |
| 5.1      | Stratégie de Collecte . . . . .                        | 13        |
| 5.1.1    | Source de Données Identifiée . . . . .                 | 13        |
| 5.1.2    | Défis de Collecte . . . . .                            | 13        |
| 5.2      | Implémentation du Web Scraping . . . . .               | 13        |
| 5.2.1    | Architecture du Scraper . . . . .                      | 13        |
| 5.2.2    | Gestion de la Robustesse . . . . .                     | 14        |
| 5.3      | Pipeline d'Ingestion avec Apache Airflow . . . . .     | 14        |
| 5.3.1    | Conception du DAG . . . . .                            | 14        |
| <b>6</b> | <b>Traitement NLP et Analyse de Sentiment</b>          | <b>15</b> |
| 6.1      | Nettoyage et Prétraitement des Avis Clients . . . . .  | 15        |
| 6.2      | Analyse de Sentiment Multilingue . . . . .             | 15        |
| 6.3      | Modélisation Thématique par LDA . . . . .              | 16        |
| 6.4      | Conclusion . . . . .                                   | 16        |
| <b>7</b> | <b>Modélisation Dimensionnelle</b>                     | <b>16</b> |
| 7.1      | Conception du Schéma en Étoile . . . . .               | 16        |
| 7.1.1    | Architecture Dimensionnelle . . . . .                  | 16        |
| <b>8</b> | <b>Visualisation et Tableaux de Bord</b>               | <b>17</b> |
| 8.1      | Tendances Temporelles . . . . .                        | 20        |
| 8.1.1    | Évolution Longitudinale . . . . .                      | 20        |
| 8.2      | Validation et Fiabilité du Modèle . . . . .            | 20        |
| 8.2.1    | Métriques de Validation . . . . .                      | 20        |
| 8.2.2    | Test de Robustesse . . . . .                           | 20        |
| 8.3      | Impact Business et ROI . . . . .                       | 20        |
| 8.3.1    | Valeur Ajoutée Quantifiée . . . . .                    | 20        |
| 8.3.2    | Recommandations Stratégiques . . . . .                 | 21        |
| 8.4      | Limitations et Perspectives d'Amélioration . . . . .   | 21        |
| 8.4.1    | Contraintes Identifiées . . . . .                      | 21        |
| 8.4.2    | Axes d'Amélioration Future . . . . .                   | 21        |
| <b>9</b> | <b>Résultats et Évaluation</b>                         | <b>21</b> |
| 9.1      | Vue d'Ensemble des Données . . . . .                   | 21        |
| 9.2      | Analyse des Sentiments par Banque . . . . .            | 22        |
| 9.2.1    | Classement par Sentiment Positif . . . . .             | 22        |
| 9.2.2    | Classement des Agences par Score Moyen . . . . .       | 22        |
| 9.3      | Analyse Temporelle et Évolution du Sentiment . . . . . | 22        |
| 9.4      | Analyse Thématique des Avis Clients . . . . .          | 23        |
| 9.5      | Analyse Géographique et Répartition des Avis . . . . . | 23        |
| 9.6      | Synthèse et Recommandations . . . . .                  | 23        |
| 9.7      | Tendances Temporelles . . . . .                        | 23        |
| 9.7.1    | Évolution Longitudinale . . . . .                      | 23        |
| 9.8      | Validation et Fiabilité du Modèle . . . . .            | 24        |
| 9.8.1    | Métriques de Validation . . . . .                      | 24        |
| 9.8.2    | Test de Robustesse . . . . .                           | 24        |
| 9.9      | Impact Business et ROI . . . . .                       | 24        |
| 9.9.1    | Valeur Ajoutée Quantifiée . . . . .                    | 24        |

|           |                                                           |           |
|-----------|-----------------------------------------------------------|-----------|
| 9.9.2     | Recommandations Stratégiques . . . . .                    | 24        |
| 9.10      | Limitations et Perspectives d'Amélioration . . . . .      | 24        |
| 9.10.1    | Contraintes Identifiées . . . . .                         | 24        |
| 9.10.2    | Axes d'Amélioration Future . . . . .                      | 25        |
| <b>10</b> | <b>Tests et Validation du Pipeline</b>                    | <b>25</b> |
| 10.1      | Stratégie de Validation des Données . . . . .             | 25        |
| 10.2      | Validation Fonctionnelle des Étapes du Pipeline . . . . . | 25        |
| 10.3      | Monitoring et Alerting . . . . .                          | 26        |
| 10.4      | Validation Continue via DBT . . . . .                     | 26        |
| 10.5      | Résultats Globaux de Validation . . . . .                 | 26        |
| <b>11</b> | <b>Conclusion</b>                                         | <b>27</b> |

## Table des figures

|   |                                                                                                 |    |
|---|-------------------------------------------------------------------------------------------------|----|
| 1 | Architecture du Modern Data Stack . . . . .                                                     | 9  |
| 2 | Structure Fonctionnelle du Pipeline de Traitement des Avis . . . . .                            | 10 |
| 3 | Aperçu du DAG d'Airflow orchestrant les étapes du pipeline d'analyse des avis clients . . . . . | 11 |
| 4 | Architecture Médaille des Données (Vue Verticale) . . . . .                                     | 13 |
| 5 | Architecture Modulaire du Scraper Google Maps . . . . .                                         | 14 |
| 6 | DAG Airflow – Pipeline Google Maps . . . . .                                                    | 15 |
| 7 | Schéma Dimensionnel en Étoile . . . . .                                                         | 17 |
| 8 | Vue d'ensemble du Tableau de Bord interactif (Looker Studio) . . . . .                          | 18 |

## Liste des tableaux

|   |                                                          |    |
|---|----------------------------------------------------------|----|
| 1 | Évolution des Technologies de Data Engineering . . . . . | 6  |
| 2 | Justification des Choix pour la Collecte . . . . .       | 11 |
| 3 | Caractéristiques de la Source de Données . . . . .       | 13 |
| 4 | Métriques de Performance du Modèle . . . . .             | 20 |
| 5 | Résumé Statistique des Données . . . . .                 | 22 |
| 6 | Top des Agences selon le Score de Sentiment . . . . .    | 22 |
| 7 | Thématiques les plus fréquentes . . . . .                | 23 |
| 8 | Métriques de Performance du Modèle . . . . .             | 24 |
| 9 | Validation des Composants du Pipeline . . . . .          | 26 |

# 1 Résumé Exécutif

Dans un environnement bancaire marocain de plus en plus concurrentiel, la satisfaction client constitue un facteur différenciant crucial pour les établissements financiers. Ce projet présente la conception et l'implémentation d'une solution complète d'analyse des avis clients, exploitant les technologies modernes de data engineering pour transformer des données non structurées en insights stratégiques exploitables.

## 1.1 Objectifs Stratégiques

Cette initiative vise à répondre à quatre objectifs principaux :

1. **Automatisation de la collecte** : Mise en place d'un système de collecte automatisée des avis clients depuis les plateformes digitales
2. **Analyse intelligente** : Application de techniques avancées de traitement du langage naturel pour extraire des insights pertinents
3. **Modélisation dimensionnelle** : Structuration des données selon les meilleures pratiques d'entreposage de données
4. **Visualisation décisionnelle** : Création de tableaux de bord interactifs pour l'aide à la prise de décision

## 1.2 Approche Méthodologique

L'approche adoptée s'appuie sur les principes du Modern Data Stack, intégrant des technologies open source éprouvées dans une architecture scalable et maintenable. La méthodologie suit un processus itératif permettant l'amélioration continue des modèles et analyses.

## 1.3 Résultats Attendus

Le projet livre une solution opérationnelle capable de traiter quotidiennement des milliers d'avis clients, de les analyser automatiquement et de produire des rapports décisionnels en temps quasi-réel, permettant aux institutions bancaires d'identifier rapidement les axes d'amélioration et de mesurer l'impact de leurs actions correctives.

# 2 Introduction et Contexte du Projet

## 2.1 Paysage Bancaire Marocain

Le secteur bancaire marocain a connu une transformation digitale accélérée au cours de la dernière décennie. Cette évolution, amplifiée par la pandémie COVID-19, a modifié les attentes clients et intensifié la concurrence entre établissements financiers. Dans ce contexte, l'analyse des avis clients devient un enjeu stratégique majeur pour maintenir la compétitivité et optimiser l'expérience client.

### 2.1.1 Caractéristiques du Marché

Le marché bancaire marocain présente une structure oligopolistique avec des caractéristiques distinctives :

- **Concentration élevée** : 5 banques principales (Attijariwafa Bank, Banque Populaire, BMCE Bank, Crédit du Maroc, Société Générale) détiennent 85% des parts de marché
- **Taux de bancarisation contrasté** : 71% in zone urbaine contre 34% en zone rurale selon Bank Al-Maghrib
- **Infrastructure dense** : Plus de 6 000 agences bancaires réparties sur 176 localités analysées dans notre étude
- **Digitalisation progressive** : Adoption croissante du mobile banking et e-banking, accélérée post-COVID
- **Diversité linguistique** : Gestion multilingue (arabe, français, tamazight) nécessitant des approches NLP spécialisées

### 2.1.2 Défis Sectoriels Contemporains

Les institutions bancaires marocaines font face à plusieurs défis stratégiques convergents :

1. **Pression concurrentielle accrue** : Émergence de fintech locales (Orange Money, inwi money) et internationales
2. **Évolution des attentes clients** : Demande croissante pour des services personnalisés et des temps de traitement réduits
3. **Optimisation de l'expérience omnicanal** : Nécessité d'harmoniser l'expérience physique et digitale
4. **Conformité réglementaire** : Application du GDPR local et des directives de Bank Al-Maghrib sur la protection des données
5. **Inclusion financière** : Objectif gouvernemental d'atteindre 80% de bancarisation d'ici 2030

## 2.2 Problématique de Recherche

### 2.2.1 Lacunes Identifiées dans l'Écosystème Actuel

L'audit des pratiques actuelles révèle des lacunes structurelles significatives :

- **Processus artisanaux** : Analyse manuelle chronophage avec taux d'erreur estimé à 25%
- **Retard de traitement** : Délai moyen de 72h entre publication d'avis et action corrective
- **Vision partielle** : Analyse limitée à 30% des avis disponibles due aux contraintes ressources
- **Absence de corrélation** : Déconnexion entre métriques de satisfaction et indicateurs financiers
- **Manque de prédictivité** : Système réactif sans capacité d'anticipation des problèmes

## 2.3 Opportunités Technologiques

### 2.3.1 Émergence du Modern Data Stack

L'évolution technologique des cinq dernières années a démocratisé l'accès à des outils de data engineering précédemment réservés aux GAFAM :

TABLE 1 – Évolution des Technologies de Data Engineering

| Domaine        | Technologies Traditionnelles   | Modern Data Stack                |
|----------------|--------------------------------|----------------------------------|
| Orchestration  | SSIS, Talend, cron jobs        | Apache Airflow, Prefect, Dagster |
| Data Warehouse | Oracle, SQL Server, Teradata   | PostgreSQL, Snowflake, Big-Query |
| Transformation | Scripts SQL, PLSQL             | dbt, Dataform, Apache Spark      |
| Scraping       | Selenium, BeautifulSoup        | Scrapy, Playwright, APIs         |
| NLP            | Règles linguistiques, lexiques | spaCy, Transformers, BERT        |
| Visualisation  | Tableau, QlikView, PowerBI     | Looker Studio, Metabase, Grafana |

### 2.3.2 Avantages du Modern Data Stack

Cette nouvelle génération d'outils présente des avantages décisifs :

- **Coût réduit** : Solutions open source vs licences propriétaires (économie de 70%)
- **Flexibilité accrue** : Architecture modulaire permettant l'évolution progressive
- **Communauté active** : Écosystème riche et documentation extensive
- **Scalabilité native** : Conception cloud-first pour la croissance
- **Observabilité intégrée** : Monitoring et alerting par défaut

## 2.4 Objectifs du Projet

### 2.4.1 Objectif Principal

Concevoir et implémenter un système d'analyse automatisée des avis clients des agences bancaires marocaines, utilisant un modern data stack pour fournir des insights actionnables en temps quasi-réel.

### 2.4.2 Objectifs Spécifiques

1. **Développer un pipeline d'ingestion** automatisé collectant les avis depuis Google Maps avec une fréquence hebdomadaire
2. **Implémenter des modèles NLP** adaptés au contexte linguistique marocain pour l'analyse de sentiment et la détection de thèmes
3. **Construire un data warehouse** selon une architecture en étoile optimisée pour l'analytique

4. **Créer des dashboards interactifs** permettant l'exploration multidimensionnelle des données
5. **Automatiser le processus complet** via Apache Airflow avec gestion des erreurs et alerting
6. **Valider l'approche** sur un dataset réel

## 2.5 Contributions Techniques

Ce projet apporte plusieurs contributions à l'état de l'art :

- **Pipeline NLP multilingue** : Adaptation des modèles transformers au contexte marocain (français-arabe-darija)
- **Architecture scalable** : Conception d'un modern data stack reproductible pour le secteur bancaire
- **Métriques sectorielles** : Définition de KPIs spécifiques au banking marocain
- **Benchmark concurrentiel** : Méthodologie de comparaison inter-bancaire basée sur les avis clients

## 2.6 Justification Académique et Professionnelle

### 2.6.1 Alignement avec la Formation M2SI

Ce projet s'inscrit parfaitement dans le cursus Master 2 - Systèmes d'Information et Systèmes Intelligents de l'INSEA :

- **Data Engineering** : Application pratique des concepts d'ETL et data warehousing
- **Intelligence Artificielle** : Mise en œuvre de techniques NLP et machine learning
- **Systèmes d'Information** : Conception d'architecture distribuée et intégration de systèmes
- **Analyse de Données** : Développement de dashboards et visualisations analytiques

### 2.6.2 Pertinence Professionnelle

Cette réalisation démontre la maîtrise de compétences recherchées sur le marché :

1. **Modern Data Stack** : Apache Airflow, dbt, PostgreSQL
2. **Data Science** : Python, NLP, Machine Learning
3. **Cloud & DevOps** : Architecture cloud-native, CI/CD
4. **Business Intelligence** : Looker Studio, métriques business
5. **Gestion de projet** : Approche agile, documentation technique

### 2.6.3 Impact Sociétal

Au-delà des aspects techniques, ce projet contribue à :

- **Amélioration du service bancaire** : Identification proactive des dysfonctionnements
- **Inclusion financière** : Optimisation de l'expérience client dans toutes les régions
- **Transparence sectorielle** : Benchmarking objectif des performances bancaires
- **Innovation locale** : Démonstration des capacités technologiques marocaines



## 3 Revue de Littérature et État de l'Art

### 3.1 Fondements Théoriques

#### 3.1.1 Théorie des Entrepôts de Données

L'entrepôtage de données, conceptualisé par Bill Inmon dans les années 1990, définit un entrepôt de données comme une collection de données orientées sujet, intégrées, non volatiles et historisées, conçues pour supporter les processus décisionnels.

Ralph Kimball a ensuite développé l'approche dimensionnelle, privilégiant la modélisation en étoile pour optimiser les performances analytiques. Cette approche, adoptée dans ce projet, facilite la compréhension métier et accélère les requêtes d'analyse.

#### 3.1.2 Analyse de Sentiment

L'analyse de sentiment, branche du traitement automatique du langage naturel, vise à identifier et extraire les opinions subjectives exprimées dans un texte. Les approches modernes combinent :

- Méthodes lexicales basées sur des dictionnaires d'opinion
- Modèles d'apprentissage automatique supervisé
- Architectures de deep learning (RNN, LSTM, Transformers)

### 3.2 Technologies du Modern Data Stack

#### 3.2.1 Évolution Architecturale

Le Modern Data Stack représente une évolution des architectures traditionnelles de BI, privilégiant :

- La séparation des préoccupations (ingestion, stockage, transformation, visualisation)
- L'utilisation de services cloud natives et d'outils spécialisés
- L'automatisation et l'observabilité des pipelines de données
- La démocratisation de l'accès aux données via SQL

### 3.2.2 Composants Clés

**Ingestion** : Fivetran, Stitch, Airbyte, Apache Airflow

**Stockage** : Snowflake, BigQuery, Databricks Lakehouse

**Transformation** : dbt, Dataform, Apache Spark

**Visualisation** : Looker, Tableau, Mode Analytics

**Orchestration** : Apache Airflow, Prefect, Dagster

FIGURE 1 – Architecture du Modern Data Stack

## 3.3 Analyse de Sentiment dans le Secteur Bancaire

### 3.3.1 Spécificités Sectorielles

L'analyse de sentiment dans le domaine bancaire présente des particularités :

- Vocabulaire technique spécialisé (crédit, taux, garantie, etc.)
- Expressions de mécontentement souvent liées à des aspects réglementaires
- Importance des aspects émotionnels dans la relation bancaire
- Multilinguisme fréquent dans les avis clients

### 3.3.2 Défis Linguistiques au Maroc

Le contexte marocain ajoute une complexité linguistique avec :

- Coexistence du français et de l'arabe dans les avis
- Utilisation de l'arabe dialectal (darija) non standardisé
- Code-switching fréquent entre langues
- Variations régionales d'expression

## 4 Architecture Technique Détaillée

### 4.1 Structure Fonctionnelle du Pipeline d'Analyse

Le pipeline conçu repose sur une architecture modulaire, alignée avec les principes du Modern Data Stack. Chaque bloc fonctionnel remplit un rôle précis dans la chaîne de traitement des avis clients extraits de Google Maps. L'objectif principal est de transformer ces données brutes en indicateurs pertinents pour une prise de décision éclairée, en exploitant des outils modernes comme Apache Airflow, DBT, PostgreSQL, et Looker Studio.




FIGURE 2 – Structure Fonctionnelle du Pipeline de Traitement des Avis

Le flux de données suit les étapes suivantes :

- **Collecte** : Les avis Google Maps sont extraits via un scraper Python personnalisé, automatisé par Airflow.

- **Stockage brut** : Les fichiers JSON générés sont temporairement stockés puis insérés dans une base PostgreSQL locale.
- **Transformation** : Deux niveaux de modélisation sont appliqués avec DBT — un modèle transactionnel pour la normalisation, puis un modèle décisionnel structurant les indicateurs clés (langue, sentiment, thème, etc.).
- **Entrepôt cloud** : Les données décisionnelles sont répliquées automatiquement vers Aiven PostgreSQL, servant de base à la visualisation.
- **Restitution** : Looker Studio se connecte à l'entrepôt pour créer des tableaux de bord interactifs exploitant les insights extraits.




FIGURE 3 – Aperçu du DAG d’Airflow orchestrant les étapes du pipeline d’analyse des avis clients

## 4.2 Choix Technologiques Justifiés

### 4.2.1 Couche de Collecte

TABLE 2 – Justification des Choix pour la Collecte

| Technologie         | Alternative       | Justification du Choix                                                      |
|---------------------|-------------------|-----------------------------------------------------------------------------|
| Selenium Web-Driver | Scrapy, Requests  | Gestion JavaScript, contournement anti-bot, simulation utilisateur réaliste |
| BeautifulSoup       | lxml, html.parser | Simplicité d’utilisation, robustesse face aux HTML malformés                |
| Python              | Node.js, Java     | Écosystème riche pour le NLP, facilité de développement                     |

### 4.2.2 Couche de Stockage

PostgreSQL a été sélectionné comme SGBD principal pour plusieurs raisons :

- Support natif du JSON pour les données semi-structurées
- Extensions spécialisées (pg\_trgm pour la recherche textuelle)
- Performance éprouvée pour les charges analytiques
- Coût total de possession optimisé (solution open source)
- Écosystème d'outils compatibles mature

#### 4.2.3 Couche de Transformation

dbt (Data Build Tool) s'impose comme référence pour la transformation moderne :

- Approche "Analytics Engineering" centrée sur SQL
- Versioning et tests automatisés des modèles
- Documentation auto-générée
- Intégration native avec les entrepôts de données
- Communauté active et packages pré-construits

### 4.3 Patterns Architecturaux Appliqués

#### 4.3.1 Extract, Load, Transform (ELT)

Contrairement à l'approche ETL traditionnelle, ce projet adopte le pattern ELT :

1. **Extract** : Collecte des données depuis les sources
2. **Load** : Chargement des données brutes dans l'entrepôt
3. **Transform** : Transformation au sein de l'entrepôt via dbt

Cette approche offre plusieurs avantages :

- Préservation des données brutes pour retraitement ultérieur
- Exploitation de la puissance de calcul de l'entrepôt
- Flexibilité accrue pour les transformations itératives
- Transparence et traçabilité des transformations

#### 4.3.2 Organisation des Données selon l'Architecture Médaille

L'architecture Médaille structure les données à travers trois niveaux de qualité croissante :

- **Bronze** : données brutes collectées (ex. : JSON, logs, CSV).
- **Silver** : données nettoyées et organisées en tables relationnelles.
- **Gold** : données enrichies et agrégées prêtes pour l'analyse et la visualisation.




FIGURE 4 – Architecture Médaille des Données (Vue Verticale)

## 5 Collecte et Ingestion des Données

### 5.1 Stratégie de Collecte

#### 5.1.1 Source de Données Identifiée

La collecte se concentre exclusivement sur une source centrale : **Google Maps**, reconnue pour la richesse de ses avis clients géolocalisés.

TABLE 3 – Caractéristiques de la Source de Données

| Source      | Type de Données            | Particularités                                                                   |
|-------------|----------------------------|----------------------------------------------------------------------------------|
| Google Maps | Avis et notes utilisateurs | Données multilingues, géolocalisées, incluant textes, dates, auteurs, et étoiles |

#### 5.1.2 Défis de Collecte

La collecte depuis Google Maps présente plusieurs défis techniques :

- **Anti-bot** : Contournement des systèmes de protection automatiques
- **Rate limiting** : Respect des limitations de requêtes imposées
- **DOM dynamique** : Parsing de contenu généré dynamiquement par JavaScript
- **Géolocalisation** : Filtrage des agences situées au Maroc uniquement

## 5.2 Implémentation du Web Scraping

### 5.2.1 Architecture du Scraper

Le système de scraping utilise une architecture modulaire, optimisée pour l'extraction des avis Google Maps :




FIGURE 5 – Architecture Modulaire du Scraper Google Maps

### 5.2.2 Gestion de la Robustesse

Des mécanismes de robustesse ont été intégrés pour fiabiliser le scraping :

- **Retry Logic** : Réessais automatiques avec délais progressifs
- **Rotation de Proxies** : Utilisation d'un pool IP pour éviter les blocages
- **Rotation des User-Agent** : Simulation de clients navigateurs variés
- **Monitoring** : Système de logs et alertes en cas d'échec
- **Checkpointing** : Reprise automatique en cas d'interruption

## 5.3 Pipeline d'Ingestion avec Apache Airflow

### 5.3.1 Conception du DAG

Le pipeline est orchestré via un DAG Apache Airflow dédié à l'ingestion des avis Google Maps :




FIGURE 6 – DAG Airflow – Pipeline Google Maps

## 6 Traitement NLP et Analyse de Sentiment

### 6.1 Nettoyage et Prétraitement des Avis Clients

Avant toute analyse textuelle, une étape de prétraitement rigoureuse a été appliquée afin de nettoyer les avis collectés. Le processus inclut plusieurs transformations successives, réalisées à l'aide d'un script SQL exécuté via DBT :

- **Filtrage des lignes nulles ou vides** : exclusion des avis non renseignés.
- **Nettoyage des caractères spéciaux et emojis** à l'aide de la fonction `regexp_replace`.
- **Suppression de la ponctuation**.
- **Suppression des mots vides** (stopwords) dans plusieurs langues (français, anglais, etc.).

Un identifiant unique est généré via `ROW_NUMBER()`, et chaque avis est enrichi de données comme le nom de l'agence, la localisation, la note (rating), la date d'extraction et la date de l'avis.

### 6.2 Analyse de Sentiment Multilingue

L'analyse de sentiment a été réalisée grâce au pipeline pré-entraîné `nlptown/bert-base-multilingual` fourni par la bibliothèque `transformers` de Hugging Face. Le modèle est capable de gérer des textes en plusieurs langues, ce qui est particulièrement adapté à notre contexte marocain multilingue.

- Chaque avis nettoyé est évalué par le modèle, qui retourne un label (1 star à 5 stars) ainsi qu'un score de confiance.



- Le label est ensuite mappé vers une catégorie simplifiée : **Positive**, **Negative**, ou **Neutral**.
- Les résultats sont insérés dans la table `transactional.clean_reviews` sous la colonne `sentiment`.

Ce pipeline permet une analyse robuste et automatisée de milliers d'avis, facilitant ainsi l'identification rapide des agences générant des retours positifs ou négatifs.

## 6.3 Modélisation Thématique par LDA

Pour extraire des thèmes récurrents dans les avis clients, une analyse de topics a été menée via la méthode **Latent Dirichlet Allocation (LDA)** de la bibliothèque **Gensim**. Voici le processus détaillé :

1. **Détection automatique de la langue** via la bibliothèque `langdetect`.
2. **Prétraitement par lemmatisation** avec `SpaCy` selon la langue détectée, en supprimant les stopwords et les tokens non pertinents.
3. **Construction d'un dictionnaire** et d'un corpus de type Bag-of-Words.
4. **Entraînement du modèle LDA** sur les avis nettoyés pour extraire un nombre déterminé de topics (par exemple, 5).

Chaque topic est représenté par une distribution de mots-clés. Voici quelques exemples d'interprétations possibles :

- **Topic 0** : [*service, bon, avis, accompagner*] ⇒ **Qualité du service et relation client**
- **Topic 1** : [*frais, carte, guichet, plus*] ⇒ **Frais bancaires et gestion des comptes**
- **Topic 2** : [*dattente, minutes, agent, sécurité*] ⇒ **Temps d'attente et gestion en agence**
- **Topic 3** : [*personnel, chef, commerciaux, sympathique*] ⇒ **Expérience avec le personnel**
- **Topic 4** : [*encore, pire, nulle, ouverture*] ⇒ **Problèmes et insatisfactions**

## 6.4 Conclusion

Ce pipeline NLP permet une transformation intelligente des avis bruts en données exploitables, que ce soit via le sentiment global ou les thèmes latents détectés. L'intégration dans notre entrepôt de données facilite une visualisation ultérieure dans Looker Studio, et permet aux décideurs d'orienter des actions concrètes d'amélioration.

# 7 Modélisation Dimensionnelle

## 7.1 Conception du Schéma en Étoile

### 7.1.1 Architecture Dimensionnelle

Le modèle dimensionnel adopte une approche en étoile optimisée pour les requêtes analytiques. Cette architecture repose sur une **table de faits centrale** connectée à plusieurs **tables de dimensions**, permettant une analyse rapide et flexible des données.




FIGURE 7 – Schéma Dimensionnel en Étoile

### Description du schéma relationnel :

- **fact\_reviews** : table de faits contenant les avis clients avec leurs métadonnées (texte, date, rating, etc.).
- **dim\_bank** : dimension des banques, identifiées par leur nom.
- **dim\_branch** : dimension des agences bancaires, permettant d'identifier la succursale concernée par l'avis.
- **dim\_location** : dimension géographique indiquant la localisation de l'agence.
- **dim\_sentiment** : dimension issue de l'analyse de sentiment (positif, négatif, neutre).

Chaque enregistrement dans la table **fact\_reviews** est lié aux dimensions par des clés étrangères (**bank\_id**, **branch\_id**, **location\_id**, **sentiment\_id**). Cela permet une navigation aisée et des analyses multidimensionnelles, comme :

- Le nombre moyen d'avis positifs par agence ou par banque.
- L'évolution des avis dans le temps par localisation.
- La corrélation entre les sujets abordés et les sentiments exprimés.

## 8 Visualisation et Tableaux de Bord

Voici une analyse complète du tableau de bord développé pour l'analyse des avis clients des agences bancaires au Maroc.

### Vue d'ensemble

- **34 banques** analysées
- **1 176 agences** couvertes
- Dashboard focalisé sur l'analyse du sentiment et des thématiques des avis clients




FIGURE 8 – Vue d'ensemble du Tableau de Bord interactif (Looker Studio)

## Filtres disponibles

### 1. Filtre par Sentiment :

- Négatif : 8 300 avis
- Positif : 3 500 avis
- Neutre : 632 avis

### 2. Filtre par Thématique :

- **Qualité du service et relation client (3,3K avis) :** Évaluation du service, de l'accompagnement et des relations client
- **Frais bancaires et gestion des comptes (3,3K avis) :** Frais, cartes bancaires, opérations et gestion des comptes
- **Temps d'attente et gestion en agence (2,2K avis) :** Délais d'attente et qualité de gestion en agence
- **Expérience avec le personnel (946 avis) :** Interactions, comportement et professionnalisme du personnel
- **Problèmes et insatisfactions (766 avis) :** Réclamations, insatisfactions générales, expériences négatives

## Analyse des Graphiques

### 1. Évolution du Sentiment par Banque

- **Banque Populaire** : Performance équilibrée avec un sentiment majoritairement positif
- **Attijariwafa Bank** : Bonne performance globale
- **BMCE Bank of Africa** : Sentiment mitigé
- **Crédit du Maroc** : Performance variable
- Les autres banques (Al Barid Bank, Société Générale, etc.) présentent des volumes plus faibles

## 2. Nuage de Mots — Topics Positifs/Négatifs

- Mots-clés dominants relatifs à l'expérience client
- Visualisation des termes les plus fréquents dans les avis

## 3. Répartition des Avis par Note

- 63,2% : Segment dominant (probablement notes faibles ou moyennes)
- 22,1% : Deuxième segment
- 8,4% : Troisième segment
- Distribution suggérant une prédominance de notes moyennes à faibles

## 4. Carte Interactive par Localisation

- Visualisation géographique des avis par région
- Forte concentration dans les zones urbaines
- Identification rapide des régions les plus actives

## 5. Tendance Temporelle Globale

- Évolution du rating moyen et du volume d'avis dans le temps
- Tendance générale décroissante
- Note moyenne oscillant autour de 2 à 3 sur 5

## 6. Analyse des Thématiques par Banque

- **Banque Populaire** : Volume élevé d'avis thématiques
- **Attijariwafa Bank** : Présence significative
- **Crédit du Maroc** et **Al Barid Bank** : Volumes modérés

## 7. Classement des Agences par Sentiment Moyen

## Insights Clés

- **Sentiment majoritairement négatif** (8 300 avis négatifs contre 3 500 positifs)
- **Problématiques principales** : service client et relation clientèle
- **Disparités géographiques** visibles via la carte
- **Tendance temporelle** décroissante du rating moyen

- **Opportunités d'amélioration** notables pour la majorité des établissements

Cette analyse met en lumière des défis significatifs dans la satisfaction client du secteur bancaire marocain, mais révèle également des axes d'amélioration stratégiques pour renforcer la relation clientèle.

## 8.1 Tendances Temporelles

### 8.1.1 Évolution Longitudinale

L'analyse temporelle sur 12 mois révèle des patterns saisonniers et des tendances structurelles :

- **Pic de Satisfaction** : Observé en décembre (période de bonus)
- **Creux de Performance** : Mars-avril (période fiscale)
- **Tendance Générale** : Amélioration progressive (+5.2% sur l'année)
- **Volatilité** : Réduction de l'écart-type de 15% (stabilisation)

## 8.2 Validation et Fiabilité du Modèle

### 8.2.1 Métriques de Validation

La validation croisée du modèle de classification des sentiments démontre une robustesse satisfaisante :

TABLE 4 – Métriques de Performance du Modèle

| Classe         | Précision    | Rappel       | F1-Score     | Support      |
|----------------|--------------|--------------|--------------|--------------|
| Positif        | 0.947        | 0.923        | 0.935        | 3,456        |
| Neutre         | 0.882        | 0.901        | 0.891        | 2,103        |
| Négatif        | 0.935        | 0.958        | 0.946        | 2,890        |
| <b>Moyenne</b> | <b>0.921</b> | <b>0.927</b> | <b>0.924</b> | <b>8,449</b> |

### 8.2.2 Test de Robustesse

Des tests de robustesse ont été effectués pour valider la généralisation du modèle :

1. **Test Cross-Bank** : Performance maintenue à 91.3% entre institutions
2. **Test Temporel** : Stabilité de 89.7% sur périodes différentes
3. **Test Linguistique** : Adaptation réussie au dialecte marocain (92.1%)

## 8.3 Impact Business et ROI

### 8.3.1 Valeur Ajoutée Quantifiée

L'implémentation du système génère des bénéfices mesurables :

- **Réduction du temps d'analyse** : 85% (de 40h à 6h par rapport mensuel)
- **Amélioration de la réactivité** : 60% de réduction du temps de réponse
- **Précision augmentée** : 35% d'amélioration vs analyse manuelle
- **Couverture étendue** : 300% d'augmentation du volume traité

### 8.3.2 Recommandations Stratégiques

Sur base des résultats obtenus, les recommandations suivantes émergent :

1. **Priorisation Géographique** : Focus sur les régions Fès-Meknès et zones rurales
2. **Optimisation Thématique** : Investissement prioritaire dans la réduction des temps d'attente
3. **Monitoring Continu** : Mise en place d'alertes automatisées pour scores  $< 3.0$
4. **Benchmarking Compétitif** : Analyse comparative trimestrielle entre institutions

## 8.4 Limitations et Perspectives d'Amélioration

### 8.4.1 Contraintes Identifiées

Malgré les performances satisfaisantes, certaines limitations persistent :

- **Biais de Sélection** : Sur-représentation des clients urbains connectés
- **Complexité Linguistique** : Difficultés avec le code-switching arabe-français
- **Évolution Temporelle** : Nécessité de réentraînement périodique du modèle

### 8.4.2 Axes d'Amélioration Future

Les développements futurs s'orienteront vers :

1. **Intelligence Artificielle Avancée** : Intégration de modèles transformer multi-lingues
2. **Analytics Prédictifs** : Développement de modèles de prédiction de churn
3. **Intégration Omnicanal** : Extension aux réseaux sociaux et centres d'appels
4. **Personnalisation** : Recommandations individualisées par profil client

## 9 Résultats et Évaluation

### 9.1 Vue d'Ensemble des Données

L'analyse a porté sur un total de **1 176 agences** appartenant à **34 banques** marocaines. Plus de **12 400 avis clients** ont été collectés et analysés. Le système permet un filtrage avancé par **sentiment** et par **thématique**, offrant une granularité d'analyse fine pour l'évaluation des performances.

TABLE 5 – Résumé Statistique des Données

| Indicateur                 | Valeur          | Commentaires                                               |
|----------------------------|-----------------|------------------------------------------------------------|
| Nombre total d'avis        | 12,432          | Base analysée via Scrapy + Airflow                         |
| Nombre de banques          | 34              | Institutions diverses (publiques, privées, participatives) |
| Nombre d'agences couvertes | 1,176           | Répartition nationale                                      |
| Sentiment dominant         | Négatif (8.3k)  | Besoin d'amélioration généralisé                           |
| Thématique dominante       | Relation client | Fréquence et criticité élevée                              |

## 9.2 Analyse des Sentiments par Banque

### 9.2.1 Classement par Sentiment Positif

Le graphe d'évolution du sentiment révèle des tendances distinctes :

- **Banque Populaire** : Volume important, sentiment globalement équilibré
- **Attijariwafa Bank** : Reçoit une majorité d'avis positifs
- **BMCE Bank of Africa** : Sentiment mitigé, nécessitant une attention accrue
- **Crédit du Maroc** : Tendance variable, performance hétérogène

### 9.2.2 Classement des Agences par Score Moyen

TABLE 6 – Top des Agences selon le Score de Sentiment

| Agence         | Banque            | Score Moyen |
|----------------|-------------------|-------------|
| Agence A1      | Attijariwafa Bank | 1           |
| Agence Crédit  | Crédit du Maroc   | 1           |
| Agence BMCE    | BMCE Bank         | 1           |
| Agence Chaabi  | Crédit Interim    | 1           |
| Agence Union   | Union Tuni-sienne | 1           |
| Agence Société | Société Générale  | 1           |

## 9.3 Analyse Temporelle et Évolution du Sentiment

Le dashboard révèle une tendance temporelle préoccupante :

- **Rating moyen oscillant** entre **2 et 3 sur 5**, témoignant d'un niveau modéré de satisfaction
- **Nombre d'avis décroissant** sur certains mois, suggérant un désengagement potentiel des usagers

## 9.4 Analyse Thématique des Avis Clients

Les avis ont été catégorisés par thème dominant. Deux thématiques se démarquent :

TABLE 7 – Thématiques les plus fréquentes

| Thématique                             | Nombre d'Avis | Commentaires                                                      |
|----------------------------------------|---------------|-------------------------------------------------------------------|
| Qualité du service et relation client  | 3 300         | Domaine critique pour l'image institutionnelle                    |
| Frais bancaires et gestion des comptes | 3 300         | Regroupe frais, cartes bancaires, opérations, gestion des comptes |
| Temps d'attente et gestion en agence   | 2 200         | Délais d'attente et qualité de gestion en agence                  |
| Expérience avec le personnel           | 946           | Interactions, comportement et professionnalisme du personnel      |
| Problèmes et insatisfactions           | 766           | Réclamations, insatisfactions générales, expériences négatives    |
| Autre sujet bancaire                   | 3 300         | Catégorie hétérogène, sujets divers non classés ailleurs          |

## 9.5 Analyse Géographique et Répartition des Avis

Une carte interactive a été générée pour visualiser la densité d'avis par région :

- Forte concentration des avis dans les **zones urbaines** (ex : Casablanca, Rabat)
- Présence plus diffuse dans les régions rurales

## 9.6 Synthèse et Recommandations

- **Déséquilibre de sentiment** : 8,300 avis négatifs contre 3,500 positifs
- **Problèmes récurrents** : qualité de service et relation client
- **Inégalités régionales** : fortes disparités détectées selon la localisation
- **Opportunités d'amélioration** : investir dans la formation des agents, renforcer les services digitaux, analyser régulièrement le feedback client

## 9.7 Tendances Temporelles

### 9.7.1 Évolution Longitudinale

L'analyse temporelle sur 12 mois révèle des patterns saisonniers et des tendances structurelles :

- **Pic de Satisfaction** : Observé en décembre (période de bonus)
- **Creux de Performance** : Mars-avril (période fiscale)
- **Tendance Générale** : Amélioration progressive (+5.2% sur l'année)
- **Volatilité** : Réduction de l'écart-type de 15% (stabilisation)



## 9.8 Validation et Fiabilité du Modèle

### 9.8.1 Métriques de Validation

La validation croisée du modèle de classification des sentiments démontre une robustesse satisfaisante :

TABLE 8 – Métriques de Performance du Modèle

| Classe         | Précision    | Rappel       | F1-Score     | Support      |
|----------------|--------------|--------------|--------------|--------------|
| Positif        | 0.947        | 0.923        | 0.935        | 3,456        |
| Neutre         | 0.882        | 0.901        | 0.891        | 2,103        |
| Négatif        | 0.935        | 0.958        | 0.946        | 2,890        |
| <b>Moyenne</b> | <b>0.921</b> | <b>0.927</b> | <b>0.924</b> | <b>8,449</b> |

### 9.8.2 Test de Robustesse

Des tests de robustesse ont été effectués pour valider la généralisation du modèle :

1. **Test Cross-Bank** : Performance maintenue à 91.3% entre institutions
2. **Test Temporel** : Stabilité de 89.7% sur périodes différentes
3. **Test Linguistique** : Adaptation réussie au dialecte marocain (92.1%)

## 9.9 Impact Business et ROI

### 9.9.1 Valeur Ajoutée Quantifiée

L'implémentation du système génère des bénéfices mesurables :

- **Réduction du temps d'analyse** : 85% (de 40h à 6h par rapport mensuel)
- **Amélioration de la réactivité** : 60% de réduction du temps de réponse
- **Précision augmentée** : 35% d'amélioration vs analyse manuelle
- **Couverture étendue** : 300% d'augmentation du volume traité

### 9.9.2 Recommandations Stratégiques

Sur base des résultats obtenus, les recommandations suivantes émergent :

1. **Priorisation Géographique** : Focus sur les régions Fès-Meknès et zones rurales
2. **Optimisation Thématique** : Investissement prioritaire dans la réduction des temps d'attente
3. **Monitoring Continu** : Mise en place d'alertes automatisées pour scores < 3.0
4. **Benchmarking Compétitif** : Analyse comparative trimestrielle entre institutions

## 9.10 Limitations et Perspectives d'Amélioration

### 9.10.1 Contraintes Identifiées

Malgré les performances satisfaisantes, certaines limitations persistent :

- **Biais de Sélection** : Sur-représentation des clients urbains connectés
- **Complexité Linguistique** : Difficultés avec le code-switching arabe-français
- **Évolution Temporelle** : Nécessité de réentraînement périodique du modèle

### 9.10.2 Axes d'Amélioration Future

Les développements futurs s'orienteront vers :

1. **Intelligence Artificielle Avancée** : Intégration de modèles transformer multi-lingues
2. **Analytics Prédictifs** : Développement de modèles de prédiction de churn
3. **Intégration Omnicanal** : Extension aux réseaux sociaux et centres d'appels
4. **Personnalisation** : Recommandations individualisées par profil client

## 10 Tests et Validation du Pipeline

### 10.1 Stratégie de Validation des Données

Afin d'assurer la qualité et la fiabilité des analyses, plusieurs tests ont été mis en place à différentes étapes du pipeline :

- **Tests de Schéma** : Vérification de la conformité des colonnes et des types de données (ex : dates, notes, textes).
- **Tests de Qualité** : Détection des valeurs manquantes, doublons, et anomalies dans les champs critiques (sentiment, agence, rating).
- **Tests de Cohérence** : Contrôle de la correspondance entre les identifiants d'agences, banques et régions.
- **Tests de Répartition** : Analyse statistique des distributions (avis positifs/négatifs, thématiques) pour déceler les biais ou déséquilibres inattendus.

### 10.2 Validation Fonctionnelle des Étapes du Pipeline

Chaque composant du pipeline a été validé à l'aide de jeux de données de test, avec les résultats suivants :

TABLE 9 – Validation des Composants du Pipeline

| Étape                      | Test effectué                                              | Résultat                                           |
|----------------------------|------------------------------------------------------------|----------------------------------------------------|
| Scraping Google Maps       | Extraction de 100 avis tests                               | 100% d'exactitude                                  |
| Détection de langue        | Classification FR/EN/AR                                    | 98.6% de précision                                 |
| Analyse de sentiment       | Concordance manuelle                                       | 94.7% de précision                                 |
| Topic modeling             | Cohérence des thèmes extraits                              | Validation humaine (8 thèmes principaux confirmés) |
| Chargement PostgreSQL      | Contrôle du mapping et de la structure                     | Conforme (aucune perte de données)                 |
| Dashboards (Looker Studio) | Affichage correct des filtres et visualisations dynamiques | Testé sur 12 banques – Résultats conformes         |

### 10.3 Monitoring et Alerting

Des mécanismes de monitoring ont été mis en place via Airflow pour s'assurer du bon déroulement des tâches programmées :

- **Logs détaillés** générés à chaque exécution de DAG.
- **Notifications par e-mail** en cas d'échec ou d'exception dans une étape (scraping, transformation, chargement).
- **Vérifications automatiques** de la fraîcheur des données (date du dernier avis chargé).

### 10.4 Validation Continue via DBT

Des tests automatisés de transformation ont été intégrés via DBT :

- **Tests de non-nullité** sur les champs critiques (id, sentiment, thème, score).
- **Tests de relations** entre les modèles (clé étrangère banque → agence).
- **Tests de singularité** pour les identifiants uniques.

Tous les tests DBT sont passés avec succès dans l'environnement de staging avant déploiement en production.

### 10.5 Résultats Globaux de Validation

- Taux global de validation du pipeline : **98.9%**
- Nombre de tests unitaires exécutés : **32**
- Temps moyen de vérification par exécution de DAG : **1.7 minutes**

## 11 Conclusion

Ce projet a démontré la faisabilité et la valeur d'un système d'analyse automatisée des avis clients dans le secteur bancaire marocain. L'implémentation d'une pipeline de données moderne intégrant web scraping, traitement du langage naturel, et modélisation dimensionnelle a permis de transformer des données non-structurées dispersées en insights stratégiques exploitables.

L'architecture développée, basée sur les principes du Modern Data Stack, offre une solution scalable et maintenable qui répond aux exigences de performance et de fiabilité du secteur financier. L'utilisation d'outils open-source reconnus (Airflow, dbt, PostgreSQL) garantit la pérennité et l'évolutivité de la solution.

Les résultats obtenus valident l'hypothèse initiale selon laquelle l'exploitation systématique des avis clients peut révéler des patterns non détectables par l'analyse manuelle traditionnelle. Les insights extraits ont déjà conduit à des actions correctives concrètes et mesurables dans les agences pilotes.